

SPTECH – SÃO PAULO TECH SCHOOL
GRUPO 8

Gabriela Pinheiro
Guilherme Trevizan
Lucas Hideo
Lucas Rodrigues
Willian Batista

RELATÓRIO DE ANÁLISE EXPLORATÓRIA DE DADOS

Projeto Kento Café: movimento, tempo de atendimento, clima e calendário

SÃO PAULO
2026

APRESENTAÇÃO

Este relatório apresenta a análise exploratória (EDA) da base do Projeto de Inovação do Grupo 8 para o Kento Café, cafeteria do bairro da Liberdade, em São Paulo. A base analisada (base_eda_pedidos.csv) tem **16.849 pedidos**, de 01/04/2026 a 30/09/2026, com **um registro por pedido** (chave id_pedido). Ela é montada pelo script montar_base_eda.py, que junta os pedidos do banco do sistema às bases de calendário e de clima do projeto. As evidências vêm do notebook de EDA da disciplina, executado sobre essa base.

Origem dos dados. A coleta real de pedidos ainda não começou: os pedidos analisados são **simulados**, gerados para testar o sistema e a dashboard. O clima (Open-Meteo, coordenadas da cafeteria) e os feriados (BrasilAPI e legislação de SP) são **reais**. A simulação seguiu regras definidas pelo grupo: mais movimento em fins de semana e feriados, menos movimento com chuva, mais bebidas geladas com calor, uma pessoa preparando por vez (o que forma fila nos picos) e mais cancelamentos quando a espera é longa.

Por isso, quando esta EDA encontra esses padrões, ela **reencontra as regras da simulação**, e não comportamento medido de clientes. O valor da análise está em **validar o método** — perguntas, métricas, tratamentos e testes — que será aplicado aos seis meses de coleta real. Todos os achados devem ser lidos assim, e a limitação volta a ser registrada na seção 7.

1 PERGUNTAS DE NEGÓCIO

A decisão que o projeto apoia é quando chamar um terceiro funcionário, além das duas pessoas que se revezam entre caixa e preparo. As perguntas abaixo seguem o formato métrica, recorte, comparação e decisão.

Quadro 1 – Perguntas de negócio

Pergunta	Métrica	Recorte	Comparação	Decisão que habilita
P1. Em que dias e horários o atendimento atrasa?	% de pedidos prontos em mais de 10 min	Dia da semana e hora	Dias úteis × fins de semana × feriados	Em quais turnos chamar o funcionário extra
P2. Quantos pedidos por hora a equipe de duas pessoas suporta?	% de atraso por faixa de pedidos na hora	Horas do período	Faixas de carga (até 10, 11-15, 16-20, 21+)	Gatilho de reforço a partir da previsão de pedidos por hora

Pergunta	Métrica	Recorte	Comparação	Decisão que habilita
P3. A chuva reduz o movimento?	Pedidos por dia	Dias, controlando pelo tipo de dia	Dias chuvosos × secos	Dispensar reforço em dia de chuva prevista
P4. A temperatura muda o que se vende?	% de pedidos com bebida gelada	Faixa de temperatura do dia	Frio × ameno × quente	Compra de insumos (gelo, leite) e organização do preparo
P5. Feriados e vésperas aumentam o movimento?	Pedidos por dia	Calendário	Feriado e véspera/ponte × dia comum	Antecipar a escala

Fonte: elaborado pelos autores (2026).

2 MATRIZ PERGUNTA, MÉTRICA, COLUNAS E OPERAÇÃO

As três últimas linhas mostram perguntas que a base não responde; elas voltam nas limitações.

Quadro 2 – Matriz de análise

Pergunta	Métrica	Colunas necessárias	Operação em Pandas	Tem na base?
P1. Atraso por dia e hora	atrasados ÷ concluídos	atrasou, dia_semana, hora, tipo_dia	groupby + mean; crosstab(normalize)	Sim (só pedidos concluídos)
P2. Capacidade da equipe	% de atraso por faixa de carga	pedidos_na_hora, atrasou	cut + groupby	Sim
P3. Efeito da chuva	pedidos por dia	dt_hr_pedido, dia_chuvoso, tipo_dia	groupby(data) + teste de Simpson	Parcial: só 18 dias chuvosos
P4. Clima e mix	% com bebida gelada	tem_bebida_gelada, faixa_temperatura	groupby + mean	Sim
P5. Feriados e vésperas	pedidos por dia	tipo_dia, vespera_ou_ponte	groupby(data) + mean	Parcial: 7 feriados e 9 vésperas/pontes
Efeito de eventos no bairro	pedidos por dia com evento	agenda de eventos	merge externo	Não: base de eventos descartada por baixa cobertura
Tempo de fila × tempo de preparo	minutos em cada etapa	início do preparo	diferença entre datas	Não: o sistema registra só o pedido e o pronto
Efeito do tamanho da equipe	atraso por nº de pessoas no turno	escala de funcionários	groupby	Não: a equipe (2 pessoas) não é registrada

Fonte: elaborado pelos autores (2026).

3 RELATÓRIO DE NULOS

3.1 Ausência por coluna


Apenas três das 22 colunas têm valores ausentes. As demais estão completas, inclusive as de clima e calendário, que cobrem todos os dias do período.

Quadro 3 – Valores ausentes por coluna

Coluna	Ausentes	% do total	Observação
descricao	13.808	82,0%	Campo opcional; único valor preenchido é "Para viagem"
tempo_espera_min	113	0,7%	Ausente nos mesmos registros que atrasou
atrasou	113	0,7%	Derivada de tempo_espera_min
demais 19 colunas	0	0,0%	Sem ausência

Fonte: elaborado pelos autores (2026).

Figura 1 – Ausência por coluna



Fonte: elaborado pelos autores (2026), a partir do notebook de EDA.

3.2 Nulos disfarçados

A busca por textos suspeitos ("-", "n/a", "sem dado" e similares) **não encontrou ocorrências**. Entre as numéricas, o notebook apontou o zero como possível sentinela em chuva_hora_mm (75,5% dos registros) e chuva_dia_mm (48,4%). **Não é ausência**: zero milímetro é a medida de uma hora sem chuva; quando falta dado, a origem devolve vazio, e nenhuma hora do período está sem dado.


Há o caso inverso em descricao: o vazio é um valor disfarçado de ausência. Como o único texto registrado é "Para viagem", o vazio significa, na prática, consumo no local.

3.3 Hipóteses sobre o padrão de ausência

H1. tempo_espera_min e atrasou ausentes = pedidos cancelados. Os 113 registros sem tempo de espera são exatamente os 113 pedidos cancelados, e a correlação entre as duas ausências é 1,00 (Figura 2). A ausência **não é aleatória**: os cancelados aconteceram em horas um pouco mais cheias (13,3 pedidos por hora em média, contra 12,3 nos concluídos) e mais em fins de semana e feriados (49,6% contra 40,1%). Como cancelar tende a acontecer quando a espera já está longa, a % de atraso calculada só com os concluídos fica levemente subestimada.

H2. descricao ausente = consumo no local. A comparação entre os pedidos com e sem o valor não mostra diferença nas métricas: valor mediano de R\$ 16,00 nos dois grupos, 1,55 e 1,57 itens por pedido, espera mediana de 4,1 e 4,2 minutos e carga de 12,2 e 12,3 pedidos por hora. A ausência é estrutural e não se relaciona com o problema analisado.

Figura 2 – Correlação entre as ausências



Fonte: elaborado pelos autores (2026), a partir do notebook de EDA.

4 DICIONÁRIO DE DADOS

O dicionário completo do projeto (banco da cafeteria, calendário e clima) é entregue em arquivo próprio. Abaixo, o dicionário da base analisada. **Granularidade:** um registro por pedido. **Chave:** id_pedido, sem duplicatas.

Quadro 4 – Dicionário da base analisada (base_eda_pedidos.csv)

Campo	Tipo	Descrição	Domínio	Origem
id_pedido	inteiro	Identificador do pedido	1 a 16.849	pedido.id
dt_hr_pedido	data e hora	Momento em que o pedido foi registrado	01/04 a 30/09/2026	pedido.dt_hr_pedido
pedidos_na_hora	inteiro	Pedidos feitos na mesma hora, incluindo cancelados	1 a 30	derivado
tempo_espera_min	decimal	Minutos entre o pedido e o pronto; vazio se cancelado	0,4 a 34,4	derivado
valor_total	decimal (R\$)	Valor do pedido	5,00 a 148,00	pedido.valor_total
qtd_itens	inteiro	Soma das quantidades dos itens	1 a 7	item_pedido
hora	inteiro	Hora do pedido	9 a 17	derivado
temperatura_hora_c	decimal (°C)	Temperatura na hora do pedido	11,2 a 32,6	clima horário

Campo	Tipo	Descrição	Domínio	Origem
chuva_hora_mm	decimal (mm)	Chuva na hora do pedido	0 a 11,0	clima horário
temp_max_dia_c	decimal (°C)	Temperatura máxima do dia no horário comercial	12,8 a 32,6	clima diário
chuva_dia_mm	decimal (mm)	Chuva do dia no horário comercial	0 a 15,6	clima diário
tipo_dia	texto	Classificação do dia	dia útil, fim de semana, feriado	calendário
periodo	texto	Período do dia	manhã, almoço, tarde	derivado
dia_semana	texto	Dia da semana	Segunda-feira a Domingo	calendário
dia_chuvoso	texto	Dia com 5 mm ou mais de chuva no horário comercial	sim, não	clima diário
condicao_dia	texto	Condição do tempo no dia	Sol, Nublado, Garoa, Chuva, Chuva forte	clima diário
faixa_temperatura	texto	Faixa pela máxima do dia	Frio, Ameno, Quente	clima diário
vespera_ou_ponte	texto	Dia anterior a feriado ou dia de ponte	sim, não	calendário
tem_bebida_gelada	texto	Pedido com item da categoria Bebidas Frias	sim, não	item_pedido e categoria
status	texto	Situação final do pedido	Pronto, Cancelado	status
atrasou	texto	Pedido pronto em mais de 10 minutos; vazio se cancelado	sim, não	derivado
descricao	texto	Observação geral do pedido	Para viagem ou vazio	pedido.descricao


Fonte: elaborado pelos autores (2026).

5 ANÁLISE EXPLORATÓRIA

5.1 Volume ao longo do tempo e sazonalidade

O volume semanal fica entre cerca de 550 e 750 pedidos, sem buracos nem degraus que indiquem falha de carga (Figura 3). A queda na última semana é artefato de corte: ela termina em 30/09, uma quarta-feira, e por isso tem só 249 pedidos.


Figura 3 – Volume de pedidos por semana



Fonte: elaborado pelos autores (2026), a partir do notebook de EDA.

A sazonalidade semanal é a variação mais forte da base (Figura 4): sábado (120,8 pedidos por dia) e domingo (115,7) têm cerca de 60% mais movimento que segunda e terça (75,8 e 76,0). Ao longo do dia, o pico é às 13h.

Figura 4 – Pedidos por dia da semana e por hora




Fonte: elaborado pelos autores (2026), a partir do notebook de EDA.

5.2 Variáveis numéricas


O tempo de espera é **fortemente assimétrico à direita** (assimetria 2,02; média de 5,4 minutos contra mediana de 4,2), então a mediana é a medida a reportar (Figura 5). O valor do pedido segue o mesmo padrão (mediana de R\$ 16,00, média de R\$ 19,11). Já a carga, pedidos feitos na mesma hora, é quase simétrica, com mediana de 12 pedidos por hora (Figura 6).

Figura 5 – Distribuição do tempo de espera (minutos)



Fonte: elaborado pelos autores (2026), a partir do notebook de EDA.

Figura 6 – Distribuição de pedidos feitos na mesma hora



Fonte: elaborado pelos autores (2026), a partir do notebook de EDA.

5.3 Variáveis categóricas

Entre os pedidos concluídos, **11,7% passaram de 10 minutos**. As categorias raras são as que mais pesam nas perguntas: só 8,8% dos pedidos caíram em dias chuvosos (18 dias), 4,7% em feriados (7 dias) e 0,4% em dia de chuva forte (um único dia). Pedidos para viagem são 18,0% do total.


5.4 Outliers

Pelo critério do intervalo interquartil, 4,1% dos tempos de espera ficam acima de 14,1 minutos, 4,5% dos pedidos acima de R\$ 43,50 e 2,1% das horas acima de 24 pedidos. Nenhum é erro: as esperas longas e as horas cheias são o próprio fenômeno estudado, e os pedidos caros são uma subpopulação (grupos e compra de café em grão). Nas colunas de chuva o critério não se aplica: como a maior parte dos valores é zero, qualquer chuva vira "outlier".

5.5 Relações entre pares de variáveis

O atraso cresce com o tipo de dia: 7,6% dos pedidos atrasam em dias úteis, 17,5% em fins de semana e 20,3% em feriados (Figura 7). A temperatura muda o mix: a parcela de pedidos com bebida gelada vai de 11,2% em dias frios para 26,0% em dias amenos e 47,2% em dias quentes.


Figura 7 – Tempo de espera por tipo de dia



Fonte: elaborado pelos autores (2026), a partir do notebook de EDA.

Na matriz de correlação (Figura 8), a associação com o problema é entre carga e espera (Spearman 0,37). As correlações altas, entre temperatura da hora e máxima do dia (0,85) e entre valor e itens do pedido (0,83), apontam colunas redundantes, não achados.

Figura 8 – Correlação de Pearson e de Spearman




Fonte: elaborado pelos autores (2026), a partir do notebook de EDA.

6 ANÁLISE MULTIVARIADA

6.1 Carga e espera, controlando pelo tipo de dia

Fins de semana atrasam mais, mas também têm mais pedidos por hora. Para saber se o atraso vem do tipo de dia ou da carga, a relação entre carga e espera foi repetida dentro de cada tipo de dia (Figura 9 e Quadro 5). **A relação sobrevive ao controle:** em todos os tipos de dia a espera cresce com a carga (Spearman 0,28 em dias úteis e 0,41 em fins de semana e feriados), e, com a mesma carga, as taxas de atraso ficam próximas. A diferença entre dias úteis e fins de semana se explica, em boa parte, por fins de semana terem mais horas cheias.

Figura 9 – Pedidos na hora × tempo de espera, por tipo de dia



Fonte: elaborado pelos autores (2026), a partir do notebook de EDA.

Quadro 5 – % de pedidos com mais de 10 minutos, por carga da hora e tipo de dia (n entre parênteses)

Pedidos na hora	Dia útil	Fim de semana	Feriado	Geral
até 10	3,4% (5.323)	5,0% (1.147)	4,9% (143)	3,7%
11 a 15	9,8% (3.752)	9,2% (2.220)	12,3% (309)	9,7%
16 a 20	17,1% (805)	22,0% (1.653)	26,7% (217)	20,9%
21 ou mais	54,0% (139)	45,1% (915)	49,6% (113)	46,6%

Fonte: elaborado pelos autores (2026).

Na faixa de 16 a 20 pedidos por hora, 1 em cada 5 clientes já espera mais de 10 minutos; acima de 21, quase metade.

6.2 Teste de Simpson 1: chuva e pedidos por dia, por tipo de dia

Combinação escolhida porque dias chuvosos poderiam cair mais em dias úteis, que já têm menos movimento, e o efeito da chuva no agregado seria só composição. **Não houve inversão:** a chuva reduz o movimento no agregado e dentro de cada tipo de dia, mesmo com os dias chuvosos tendo mais fins de semana (38,9% contra 26,7% dos dias secos), o que puxaria a média para cima. Com só 18 dias chuvosos, o resultado é uma hipótese, não uma conclusão.

Quadro 6 – Pedidos por dia em dias secos e chuvosos

Recorte	Dias secos	Dias chuvosos	n (secos / chuvosos)
Agregado	93,1	82,5	165 / 18 dias
Dia útil	81,5	71,5	114 / 11 dias
Fim de semana	120,1	99,9	44 / 7 dias
Feriado	—	—	7 / 0 dias

Fonte: elaborado pelos autores (2026).

6.3 Teste de Simpson 2: atraso por tipo de dia, por período

O teste verifica se a vantagem dos dias úteis se mantém em cada período do dia. O notebook sinalizou inversão, mas ela só ocorre entre feriado e fim de semana na tarde. **Para a comparação que importa, dia útil contra os demais, não há inversão:** o dia útil é o que menos atrasa nos três períodos. Os feriados somam 7 dias, então a ordem entre feriado e fim de semana não é confiável.

Quadro 7 – % de pedidos com mais de 10 minutos, por tipo de dia e período

Período	Dia útil	Fim de semana	Feriado
Manhã (até 12h)	9,7%	11,1%	19,2%
Almoço (12h-14h)	8,7%	17,8%	31,7%
Tarde (após 14h)	4,9%	20,9%	14,4%
Agregado	7,6%	17,5%	20,3%

Fonte: elaborado pelos autores (2026).

6.4 Variáveis de confusão fora da base

Três fatores que podem afetar ao mesmo tempo o movimento e o atraso não estão na base: o número real de pessoas trabalhando em cada turno (faltas e folgas),

eventos no bairro (como a feira de fim de semana na Praça da Liberdade) e a separação entre tempo de fila e tempo de preparo. Eles são tratados como limitações.

7 SÍNTESE

7.1 Achados

Procurados de propósito (respondem às perguntas da seção 1). Todos reproduzem regras da simulação e devem ser confirmados com os dados reais.

A1. Fins de semana e feriados têm mais pedidos por dia (117,3 e 112,9, contra 80,6 em dias úteis) e mais atraso (17,5% e 20,3%, contra 7,6%). Evidência: Figuras 4 e 7.

A2. O atraso cresce com a carga da hora e passa de 20% na faixa de 16 a 20 pedidos por hora, em todos os tipos de dia. Evidência: Figura 9 e Quadro 5.

A3. Dias chuvosos têm menos pedidos, inclusive dentro de cada tipo de dia (cerca de 10 pedidos a menos em dias úteis e 20 em fins de semana). Evidência: Quadro 6.

A4. A parcela de pedidos com bebida gelada vai de 11,2% em dias frios a 47,2% em dias quentes. Evidência: seção 5.5.

Encontrados por acaso (relatados como hipótese).

B1. Em dias úteis, o maior atraso é na abertura, às 9h (12,4% dos pedidos), e não no almoço; nos fins de semana, o pico é das 13h às 15h (até 25,5%).

B2. O campo descricao funciona, na prática, como marcador de pedido para viagem (18,0%).

B3. Os cancelamentos se concentram em horas cheias: 1,1% acima de 20 pedidos por hora, contra 0,5% até 10.

7.2 Hipóteses

H1. A equipe de duas pessoas satura entre 16 e 20 pedidos por hora. Verificação: repetir o Quadro 5 com os dados reais e registrar quantas pessoas estavam no turno.

H2. O atraso de abertura nos dias úteis vem de fila acumulada enquanto a loja ainda se organiza. Verificação: registrar o início do preparo, separando fila de preparo.

H3. A chuva reduz principalmente os clientes de passagem. Verificação: seis meses de dados reais e a previsão do tempo registrada no dia anterior, para medir o efeito com a informação disponível na hora de decidir.

H4. O calor desloca a venda para bebidas geladas, que usam outros insumos. Verificação: mix real por faixa de temperatura.

7.3 Decisões de tratamento

Outliers. Manter as esperas longas, as horas cheias e os pedidos de valor alto: são o fenômeno estudado ou uma subpopulação legítima. Reportar medianas, não médias.

Ausentes. Calcular as métricas de tempo só com pedidos concluídos e reportar os cancelamentos à parte. Recodificar o vazio de descrição como "consumo no local". Manter os zeros de chuva como zero.

Categorias raras. Juntar "Chuva forte" (um dia) com "Chuva". Reportar feriados com aviso de n baixo ou agrupá-los com fins de semana.

Redundâncias e cortes. Usar só uma coluna de cada par redundante (temperatura da hora ou do dia; valor ou itens) e excluir a última semana, incompleta, das séries semanais.

7.4 Limitações

L1. Os pedidos são simulados: os padrões encontrados são as regras da simulação, não comportamento medido. A base valida o método, não as conclusões.

L2. Os pedidos simulados vão das 9h às 18h, mas a cafeteria funciona das 10h às 18h30. A análise por hora precisa ser refeita com o horário real.

L3. Seis meses têm poucos casos para algumas comparações: 7 feriados, 18 dias chuvosos e 1 dia de chuva forte.

L4. A base não registra a equipe em cada turno, o tempo de fila separado do preparo nem eventos no bairro, que são possíveis variáveis de confusão.

L5. O clima vem de reanálise em grade (resolução de quilômetros) e, para decidir com antecedência, será usada a previsão, que difere do observado.

L6. Só existem registros de quem fez pedido: clientes que desistiram na fila antes de pedir não aparecem, o que subestima a demanda nos picos.